

이화여자대학교

2025학년도

학사학위 졸업논문

EfficientNet-B1을 활용한
오로라 전천 영상 자동 분류

과학교육과 지구과학교육전공

여 정 인 (2148052)

2025. 06. 27.

지도교수 김 혜 미

목 차

I. 서론	
II. 연구방법	
1. 연구 대상 및 관측 데이터셋	3
2. 태양 및 달 필터링 기준	5
3. 학습용 이미지 구성 및 분할 전략	6
4. EfficientNet-B1 구조와 전이학습	6
5. Grad-CAM 구조와 시각화 전략	10
III. 연구결과 및 해석	
1. 오로라 분류 정확도 및 한계 분석	12
2. Grad-CAM 시각화 해석	14
VI. 결론 및 논의	
1. 연구 요약 및 성과	19
2. 한계점 및 향후 연구 방향	19
참고문헌	20
부록1. 논문발표회 발표자료	22

I. 서론

오로라는 태양에서 방출된 고에너지 플라즈마가 지구 자기권에 포획되어 자기장을 따라 극지방 상공으로 진입하면서 발생하는 대기광학 현상이다. 이때 입자 중 특히 전자는 전리층에서 산소(O_2), 질소(N_2) 등의 중성 입자와 충돌하며 점진적으로 에너지를 잃고, 최종적으로 약 90km 부근에서 멈춘다. 반면 충돌을 당한 대기 입자는 들뜬 상태(excited state)가 되었다가 바닥 상태로 되돌아가는 과정에서 빛을 방출하는데, 이를 통해 오로라가 시각적으로 관측된다. 고층 대기의 경우 공기 밀도가 매우 낮아 입자 간 충돌이 적기 때문에, 일반적으로 금지된 전이(forbidden transition)가 더 자주 발생하며, 이에 따라 산소 원자에 의한 녹색 오로라(천이 시간 약 0.74초) 및 적색 오로라(약 110초)가 잘 나타난다. 질소 분자는 산소보다 다양한 전자 배치를 가져 더 다채로운 색(적색, 청색, 보라색 등)의 오로라를 형성할 수 있으며, 주로 더 낮은 고도에서 에너지가 큰 전자와 반응한다. 관측되는 오로라의 형태는 arc, radial, patchy, discrete, diffuse 등 매우 다양하지만, 실제 구조의 다양성보다는 활동 강도에 따른 오로라 타원(oval) 크기와 위치, 관측자의 시야각에 따라 달라진다. 자정 무렵 오로라 타원은 지자기극을 중심으로 약 20° 내로 수축하거나, 반대로 적도 방향으로 40° 까지 팽창하기도 한다. 이는 보통 약 2시간에 걸쳐 진행되는 서브스톰(substorm) 과정과 맞물려, 북쪽 지평선을 따라 희미한 띠가 형성된 후 급격히 밝아지며 커튼 또는 코로나 형태로 발달하는 등 동적인 변화를 보인다(안병호 & 지건화, 2016).

이처럼 오로라의 색상·형태·강도는 전리권 및 자기권의 역학 상태를 직관적으로 반영하는 중요한 지표이지만, 전천(全天) 카메라로 수집된 방대한 양의 이미지 데이터를 사람이 일일이 분류하기에는 시간적·경제적 비용이 매우 크다. 또한 오로라 영상은 경계가 불분명하고 구름, 달 빛, 광공해 등의 외란이 섞이는 경우가 많아, 전통적인 컴퓨터 비전 기법만으로는 정확한 식별이 어렵다.

최근 오로라 자동 분류 연구는 딥러닝 기반 이미지 분류 기법의 발달과 함께 다양한 전략으로 확장되고 있다. Clausen & Nickisch (2018)은 THEMIS 전천 영상 5,824장을 수작업으로 6개 클래스(arc, discrete, diffuse, cloudy, moon, clear/no aurora)로 라벨링했고, Inception-v4로부터 1,001차원 특징 벡터를 추출한 뒤 Ridge Classifier로 분류하여 전체 정확도 82%, 오로라 유무 이진 분류에서는 96%의 정확도를 얻었다. Kvammen et al. (2020)은 3,846장의 수동 라벨 이미지로 arc, breakup, colored 등 7개 클래스를 분류했고, 여러 기계학습 기법(CNN, k-NN, SVM 등)을 비교한 결과, ResNet-50 기반 모델에서 최고 성능(정확도 92%)을 기록하였다. Johnson et al. (2024)는 THEMIS 전천 영상 약 7억 장을 대상으로 SimCLR 기반의 자가지도학습(self-supervised learning)을 적용하여 잠재표현을 학습했고, 수동 라벨링한 데이터셋(5,824장)을 이용해 분류기를 미세조정하였다. Yang et al. (2021)는 수작업 라벨 없이 딥 클러스터링(deep clustering)을 적용하여 오로라 이미지를 비지도적으로 분류했고, 전체 구조 학습이 가능한 잠재 공간을 형성하였다. Nanjo et al.

(2023)는 Kiruna 지역에서 촬영된 JPEG 이미지를 활용해 RGB 임계값을 활용한 rule-based 알고리즘을 설계하여 오로라 활동을 정량화했고, 레벨 6 이상 활동이 감지되면 10분 이내에 자동 경고 이메일을 발송하는 경량화된 감시 시스템을 구축하였다. Chung et al. (2022)는 장보고기지에서 3,500장의 전천 이미지를 촬영하여 가시 오로라 빈도를 분석하였으며, 특정 시간대 및 계절별 패턴을 통계화하였다. Shiokawa et al. (2017)는 전천 카메라 데이터를 활용하여 discrete arc가 자정~새벽 4시 사이에 가장 자주 발생함을 밝혔고, 오로라 발생이 IMF Bz<0 및 AE index > 100nT일 때 강화된다는 상관관계를 제시하였다. Park et al. (2020)은 극지역 오로라의 태양 주기 및 일변화 특성을 정리하였으며, 전체적으로 자정 무렵, 춘추분기, 태양 극소기 후반기에 오로라 발생률이 높아지는 경향을 보인다고 보고하였다. 이는 향후 분류된 영상의 발생 시점을 시간·계절 변수와 연계해 해석하는 데 유용한 기반을 제공한다.

하지만 맑은 밤에 한정된 이미지만 사용하여 시간 해상도가 낮거나 천정 부근에 한정된 좁은 시야 이미지만 사용하여 공간 해상도가 낮고, 단순 혼동행렬만 분석하여 예측 근거 및 오류 패턴을 체계적으로 해석하지 못하는 경우가 많았다. 따라서 본 연구에서는 2022년~2025년 사이 총 214,890장의 Auroramax 전천 이미지를 대상으로 EfficientNet-B1 전이학습 + Grad-CAM 해석 프레임워크를 구축하여 클래스 균형과 시계열 다양성을 동시에 확보한 학습 데이터셋을 적용하였다. 이를 통해 학습 정확도뿐 아니라 softmax 확률·시각적 근거 (heatmap) 를 함께 산출하고, 다양한 관측 조건별 오류 양상을 정량 진단하였다.

II. 연구방법

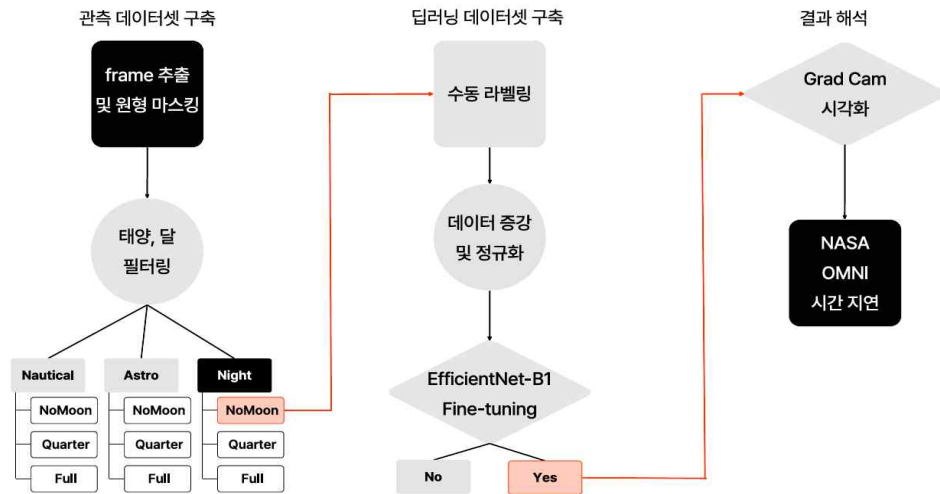


그림 1. 연구방법 전체 워크플로우.

1. 연구 대상 및 관측 데이터셋

1.1 AuroraMAX 관측소

본 연구에서 사용된 오로라 영상은 캐나다우주청(Canadian Space Agency, CSA)과 캘거리대학교(University of Calgary)가 공동 주도하는 AuroraMAX 프로젝트에서 제공하는 전천 영상을 기반으로 하였다. AuroraMAX(<https://auroramax.com/>)는 캐나다 노스웨스트 준주 Yellowknife(위도 62°26'N, 경도 114°21'W)에 설치된 전천 카메라를 통해 오로라를 실시간 고해상도로 중계하며, 오로라 및 태양 활동에 대한 대중 인식 제고를 목적으로 운영되는 공개 관측소이다.

촬영 장비는 f/4.0 조리개의 180도 어안 렌즈(fisheye lens)를 장착한 컬러 전천 카메라이며, 전천 하늘을 원형 이미지 형태로 기록한다. 영상의 외곽은 수평선(horizon), 중앙은 천정(zenith)을 포함하므로, 오로라의 발생 및 전개 양상을 전역적으로 포착할 수 있다.

1.2 영상 다운로드 및 추출 기간

사용된 MP4 영상은 AuroraMAX 공식 웹사이트에서 날짜별로 수동 다운로드하였다. 각 영상은 6초 간격으로 4초씩 노출하여 촬영된 JPG 이미지들을 약 25 fps의 타임랩스 형태로 연결한 것으로, 해상도는 1280×720(720p)이다.

카메라는 매일 일몰 직후부터 일출 직전까지 자동으로 작동되며, 촬영된 영상의 길이와 총 프레임 수는 날짜마다 달라진다. 본 연구에서는 아래 세 기간 동안의 영상을 수집하여 분석에

활용하였다:

- 2022년 12월 1일 ~ 2023년 4월 30일 (151일)
- 2024년 2월 1일 ~ 2024년 4월 30일 (90일)
- 2024년 12월 1일 ~ 2025년 2월 28일 (90일)

다운로드된 영상은 OpenCV 라이브러리를 사용하여 1분 간격($\text{fps} \times 2/5$)으로 균등 추출하였다. 또한 영상 외곽의 나무, 자동차, 눈 등의 요소를 제거하기 위해, 중심 좌표 (640, 360) 기준 반지름 360픽셀의 원형 마스크를 적용하였다. 이후 (720 × 720) 크기로 crop하여 최종 JPG 이미지로 저장하였다. 총 214,890장의 오로라 전천 이미지가 생성되었으며, 이들을 기반으로 필터링 및 학습 데이터 구성을 수행하였다.

1.3 시간 정보 추출 및 비정상 프레임 제거

AuroraMAX 영상의 하단에는 촬영 당시의 현지 시간(MST 또는 MDT) 정보가 포함되어 있으며, 날짜에 따라 여름철에는 일광절약시간제(MDT, UTC-6), 그 외 기간에는 산악표준시(MST, UTC-7)가 적용된다. 따라서 모든 시간 정보는 UTC로 변환하여 표준화할 필요가 있다.

영상 우측 하단의 시간 정보 영역을 crop한 뒤, pytesseract 라이브러리를 이용하여 문자열을 인식하였다. 인식 정확도를 높이기 위해 OpenCV 기반의 GaussianBlur 및 threshold 기법을 적용하였으며, 인식된 시간 정보 문자열은 pytz 라이브러리를 통해 North America/Yellowknife 시간대를 기준으로 UTC로 변환하였다. 변환된 시각은 이미지 파일명에 반영되어 시간순 정렬 및 분석이 가능하도록 하였다.

ex) auroramaxHD_20240201_720p.mp4

→ 텍스트 인식: 2024-01-31 18:19:54 MST

→ UTC 변환: 2024-02-01 01:19:54

→ 저장 파일명: 20240201011954_20240201_0.jpg

표 1. pytesseract로 인식한 시간 문자열에서 자주 발생하던 오류 유형별 수정 규칙.

오류 유형	교정 전 예시	교정 후 예시	설명
맨 앞 "A4" 오인	A4 -01-31 18:19:54	4 -01-31 18:19:54	A0→4 치환
맨 앞 "A0" 오인	A0 -01-31 18:19:54	4 -01-31 18:19:54	A0→4 치환
날짜 "4-" 오인	4-01- 41 18:19:54	4-01- 11 18:19:54	4→1 치환
날짜 "34" 오인	4-01- 34 18:19:54	4-01- 31 18:19:54	34→31 치환
24시 범위 초과	4-01-31 28 :19:54	4-01-31 18 :19:54	앞자리 1로 교정
5번째 "4" 추가	4-01-31 4 18:19:54	4-01-31 18:19:54	해당 문자 삭제
7번째 "4" 추가	4-01-31 18: 41 9:54	4-01-31 18:19:54	해당 문자 삭제

인식 오류를 보정하기 위해 파일명에서 날짜 및 프레임 번호를 추출하여 날짜별로 그룹화하고, 프레임 번호의 연속성 여부를 자동 검사하였다. 인식된 문자열에는 다양한 오류가 포함되었으며, 위와 같은 보정 규칙을 수동 코딩으로 구현하여 적용하였다(표 1)

2. 태양 및 달 필터링 기준

오로라는 투명하여 배경하늘의 밝기 및 색감의 영향을 많이 받으므로, 태양 고도에 따른 황혼과 달의 위상과 고도에 따른 달빛을 고려할 필요가 있다. 촬영 시점에서의 태양과 달 정보를 계산하기 위해 Skyfield 라이브러리에 NASA JPL의 천체 역학 데이터 파일인 'de421.bsp'를 불러와 적용하였다. 이때 촬영 시점은 이미지 파일명에서 추출된 UTC 시간을 활용하였고, 관측자는 Yellowknife 위치(lat = 62.4333, lon = -114.3500)로 설정하였다.

2.1 태양 고도 기반 시간대 분류

표 2. 태양 고도 조건에 따른 시간대별 이미지 분포
(총 214,890장)

Twilight	Conditional Statements	Count
Night	$\text{alt} \leq -18^\circ$	171003
Astro	$-18^\circ < \text{alt} \leq -12^\circ$	40779
Nautical	$-12^\circ < \text{alt} \leq -6^\circ$	3108
Civil	$-6^\circ < \text{alt} < 0^\circ$	-
Daytime	$\text{alt} \geq 0^\circ$	-

태양의 겉보기 고도는 Skyfield의 obs 함수를 통해 계산하였다. 계산된 고도 값은 위와 같은 기준에 따라 총 다섯 가지 시간대로 구분하였다(표 2). 전체 214,890장의 이미지 중 Night($\text{alt} \leq -18^\circ$) 조건을 만족한 이미지는 171,003장으로, 전체의 약 79.6%를 차지하였다. 그 외 Astronomical Twilight(40,779장), Nautical Twilight(3,108장) 조건의 이미지는 밝기 및 색감이 달라 오로라 탐지에 불리할 수 있기에 학습에는 사용하지 않았다. Civil Twilight과 Daytime 조건에 해당하는 이미지는 존재하지 않았다.

2.2 달 고도 및 위상 기반 달빛 조건 분류

표 3. 달 고도 및 위상 조건에 따른 달빛 단계별 이미지 분포
(총 214,890장)

Moon Phase	Conditional Statements	Count		
		Night	Astro	Nautical
No_moon	$(\text{phase} \geq 150^\circ)$ & $(\text{alt} > 5^\circ)$	98126	24149	2057
Moon_Quarter	$(45^\circ \leq \text{phase} < 150^\circ)$ & $\text{alt} > 10^\circ$	43361	10623	603
Moon_Full	else	29516	6007	448

달의 겉보기 고도는 Skyfield의 obs, 위상은 moon_phase 함수를 통해 계산하였다. 계산된 고도 및 위상 값은 위와 같은 기준에 따라 총 세 단계로 분류하였다(표 3). 전체 214,890장의 이미지 중 No_Moon 조건을 만족한 이미지는 124,332장으로, 전체의 약

57.9%를 차지하였다. 그 외 Moon_Quarter(54,587장)와 Moon_Full(35,971장) 조건은 달빛 밝기에 따라 영상의 명암 대비와 색상 분포에 영향을 줄 수 있기에 학습에는 사용하지 않았다.

3. 학습용 이미지 구성 및 분할 전략

3.1 날짜별 랜덤 샘플링 및 수작업 라벨링

오로라 영상의 학습을 위한 이미지셋을 구축하기 위해 수작업 라벨링을 수행하였다. 그러나 오로라 발생은 전체 영상의 약 30%에 불과하므로, 오로라 없는 이미지가 과도하게 많을 경우 학습 편향이 발생할 수 있다. 이를 방지하고 데이터셋의 상황적 다양성을 확보하기 위해, random 라이브러리를 사용하여 각 날짜 그룹에서 무작위로 최대 20장을 샘플링하되, 해당 날짜 그룹의 전체 이미지 수의 절반을 넘지 않도록 제한하였다.

수작업 라벨링은 “yes” 및 “no”의 이진 분류로 진행되었으며, 태양 고도와 달빛 조건을 모두 고려한 Night & No_Moon 조건의 이미지에 한정하여 수행되었다. 이때 라벨 “yes”는 오로라가 명확히 확인되는 영상, “no”는 오로라가 존재하지 않거나 뚜렷한 경계 없이 전체적으로 푸른 끼만 보이는 영상으로 정의하였다. 수작업 라벨링을 진행한 결과, 총 4,563장의 이미지가 수집되었으며, 이 중 오로라가 확인되는 “yes” 클래스는 1,353장, “no” 클래스는 3,210장이었다.

3.2 훈련 및 검증 세트 분할과 클래스 불균형 처리

라벨이 “yes”인 이미지의 경우, 각 날짜 그룹에서 80%(1,024장)는 훈련 세트로, 나머지 20%(329장)를 검증 세트로 무작위 할당하였다. 반면 “no”인 이미지의 경우 전체 이미지 수가 “yes”보다 2배 가량 많았기 때문에 단순한 비율 분할은 학습 편향을 야기할 수 있다. 이에 따라, “yes” 클래스에서 선정된 훈련·검증 세트의 이미지 수에 맞추어, “no” 클래스에서도 동일한 수만큼 이미지를 사용하였다. 각 날짜 그룹에서 약 31.88%(1,024장)는 훈련 세트, 15.05%(329장)는 검증 세트로 할당하였으며, 소수점 단위는 이미지 수가 많은 날짜부터 우선적으로 반올림 보정하여, 총 이미지 수가 정확히 맞춰지도록 구성하였다.

4. EfficientNet-B1 구조와 전이학습 전략

4.1 EfficientNet-B1 구조

본 연구에서는 정확도와 하드웨어(NVIDIA RTX 2070) 성능 제약을 함께 고려하여,

Google Brain 팀이 제안한 EfficientNet(Tan & Le, 2019) 시리즈 중 EfficientNet-B1을 기본 모델로 채택하였다. EfficientNet은 경량 합성곱 신경망(CNN) 구조인 MobileNetV2의 기본 계층(MBConv)과 채널별 가중치를 동적으로 조절하는 SE(Squeeze-and-Excitation) 모듈, 그리고 세 가지 차원을 균형 있게 확장하는 Compound Scaling 전략을 결합하여, 높은 정확도와 계산 효율성을 동시에 달성한 구조이다.

기존의 합성곱 신경망(CNN) 모델들은 보통 네트워크의 깊이(depth), 너비(width) 또는 입력 이미지 크기(resolution) 중 하나만을 확장(scaling)하여 성능을 향상시키려 하였지만, 이처럼 단일 요소만 확장할 경우 계산량 증가에 비해 정확도 향상 폭이 점차 감소하는 한계가 존재한다. 이를 해결하기 위해 EfficientNet은 세 가지 요소(깊이 α , 너비 β , 해상도 γ)를 고정된 비율로 동시에 확장하는 "Compound Scaling" 전략을 제안하였다(그림 2). 이 방식은 모델 구조의 균형을 유지하기 때문에 계산량이 증가하더라도 성능을 보다 효율적으로 높일 수 있다.

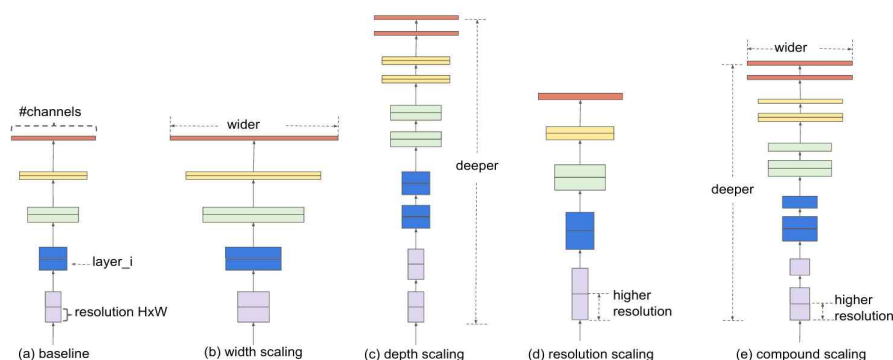


그림 2. CNN 모델 Scaling 방법 비교(Tan & Le, 2019). (a) 기본 네트워크, (b)-(d) 개별 요소만 확장한 기존 CNN Scaling, (e) 세 요소를 균형 있게 확장한 EfficientNet의 Compound Scaling.

표 4. ImageNet에서의 EfficientNet-B1 성능 결과. EfficientNet-B1은 평균 4.5배 적은 파라미터(Params)와 평균 11.2배 적은 연산량(FLOPS)으로 주요 CNN 모델과 유사한 정확도를 달성하였다.

Model	Top-1 Acc.	Top-5 Acc.	#Params	Ratio	#FLOPS	Ratio
EfficientNet-B1 (Tan & Le, 2019)	78.8%	94.4%	7.8M	1x	0.7B	1x
ResNet-152 (He et al., 2016)	77.8%	93.8%	60M	7.6x	11B	16x
DenseNet-264 (Huang et al., 2017)	77.9%	93.9%	34M	4.3x	6.0B	8.6x
Inception-v3 (Szegedy et al., 2016)	78.8%	94.4%	24M	3.0x	5.7B	8.1x
Xception (Chollet, 2017)	79.0%	94.5%	23M	3.0x	8.4B	12x

120만 장의 라벨링 이미지를 포함한 대규모 공개 데이터셋 ImageNet(Russakovsky et al., 2015)을 이용해 EfficientNet-B1과 주요 CNN 모델들의 성능을 비교한 결과는 위와 같다(표 4). EfficientNet-B1(Tan & Le, 2019)은 EfficientNet-B0에 대해 Compound Scaling 계수($\alpha=1.2$, $\beta=1.1$, $\gamma=1.15$)를 적용하여 확장된 첫 번째 모델이다. Top-1 정확도는 78.8%로 ResNet-152나 Inception-v3와 유사한 정확도를 보이면서도, 파라미터 수는 평균 4.5배 적고 연산량(FLOPS: Floating Point Operations Per Second)은 평균 11.2배 낮다. 이는 EfficientNet-B1이 정확도와 연산 효율성 간의 우수한 균형을 달성하고 있음을 보여준다.

4.2 전이학습(Fine-tuning) 과정

EfficientNet-B1은 ImageNet 데이터셋으로 미리 학습(pretraining)되어 있어, 다양한 이미지에서 시각적 특징을 효과적으로 구분할 수 있다. 따라서 사전학습 가중치(EfficientNet_B1_Weights.IMAGENET1K_V1)를 적용한 뒤, 오로라 이미지에 맞게 전이학습(fine-tuning)만 수행하였다. 원래의 출력층(classifier)은 ImageNet의 사물 카테고리 1,000개를 분류하도록 설계되어 있으므로, 본 연구에서는 오로라 유무를 판별하는 이진 분류 문제에 맞추어 마지막 fully connected 계층(FC layer)의 출력 노드 수(out_features)를 2로 수정하였다. 전이학습은 총 12 epoch 동안 두 단계로 나누어 진행하였다. 초기 6 epoch 동안은 나머지 계층(backbone)을 동결(freeze)하여 출력층(classifier)만 학습하였으며, 후반 6 epoch에서는 전체 계층의 학습을 허용하였다. 이때 후반 학습률은 과적합을 방지하기 위해 기존의 1/10로 조정하였다.

입력 이미지 크기는 ImageNet 학습 시 사용된 해상도와 동일하게 (240 × 240)으로 통일하였다. 검증 데이터(val)에는 평가의 일관성을 위해 증강을 적용하지 않았으며, 학습 데이터(train)에는 모델의 일반화 성능을 향상시키기 위해 torchvision 라이브러리의 데이터 증강 기법(RandomResizedCrop, RandomHorizontalFlip, ColorJitter)을 적용하였다(그림 3):

- RandomResizedCrop: 전체 영역의 80%~100%에 해당하는 임의의 영역을 잘라, 전체에 다양한 위치로 나타나는 오로라의 특성을 반영한다.
- RandomHorizontalFlip: 50% 확률로 이미지를 좌우 반전시켜, 방향성이 일정하지 않은 오로라의 특성을 반영한다.
- ColorJitter: 밝기(brightness), 대비(contrast), 채도(saturation)를 각각 0~0.3 범위 내에서 무작위로 조절하여, 다양한 관측 환경(달빛, 눈, 광해 등)을 모사한다.




그림 3. 오로라 이미지(raw)에 적용된 데이터 증강 기법. (a) 원본, (b) RandomResizedCrop(전체 영역의 80%를 자른 후 리사이즈), (c) HorizontalFlip(좌우 반전), (d) ColorJitter(밝기, 대비, 채도 각각 1.3배)를 각각 적용한 결과이다.

손실 함수(Loss function)는 클래스 확률 예측을 기반으로 오차를 계산하는 CrossEntropyLoss를 사용하였으며, 최적화 알고리즘(optimizer)으로는 과거 기울기를 고려하여 학습률을 적응적으로 조절하는 Adam(Adaptive Moment Estimation; Kingma & Ba, 2015)을 사용하였다.

전반적인 학습 설정은 다음과 같다(표 5):

표 5. 학습에 사용된 주요 하이퍼파라미터 및 설정.

항목	값
weight	EfficientNet_B1_Weights.IMAGENET1K_V1
Batch size	16
Learning rate	3e-4
Loss function	CrossEntropyLoss
Optimizer	Adam
Train transform	Resize(240), RandomResizedCrop(0.8-1.0), HorizontalFlip(p=0.5), ColorJitter(0.3)
Validation transform	Resize(240)
Normalize	mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225]

4.3 검증 및 이진 분류(Classification) 과정

학습이 완료된 EfficientNet-B1 모델은 실제 관측 이미지에 대해 오로라 유무를 자동 분류하는 데 활용되었다. 출력 벡터에 softmax 함수를 적용하여 두 클래스(yes/no)에 대한 정규화된 확률값을 계산한 뒤, argmax 연산을 통해 확률이 더 높은 클래스를 최종 예측으로 결정하였다. 예측 결과에 따라 오로라가 존재하는 경우는 “yes”로, 존재하지 않는 경우는 “no”로 각각 분류하였다.

5. Grad-CAM 구조와 시각화 전략

5.1 Grad-CAM 구조

학습된 EfficientNet-B1 모델이 “오로라(yes)” 또는 “비오로라(no)”를 예측할 때 주로 어떤 공간 영역을 참고하는지 시각화하기 위해 Grad-CAM(Selvaraju et al., 2017)을 적용하였다. Grad-CAM은 마지막 CNN 계층(feature map)과 최종 출력층(logit) 사이의 기울기 (gradient)를 채널별 가중치로 사용하여 입력 이미지 위에 heatmap을 생성하는 기법이다. 여기서 기울기란 역전파(backpropagation)를 통해 얻어지는 값으로, “특정 채널의 활성화 값이 변화할 때 최종 클래스 점수(logit)가 얼마나 변화하는지”를 나타낸다. 따라서 기울기의 절댓값이 클수록 해당 공간 영역이 모델의 판단(클래스 점수)에 더 큰 영향을 준 것으로 해석할 수 있다. 이때 얻어진 채널별 기울기 가중치를 각 채널 활성화 값에 곱해 가중합 한 후, ReLU(Rectified Linear Unit) 함수를 적용하여 음의 기여도를 제거한 heatmap을 생성한다. 최종적으로 이 heatmap을 원본 이미지와 결합함으로써 모델이 판단 과정에서 주목한 영역을 직관적으로 확인할 수 있다(그림 4).

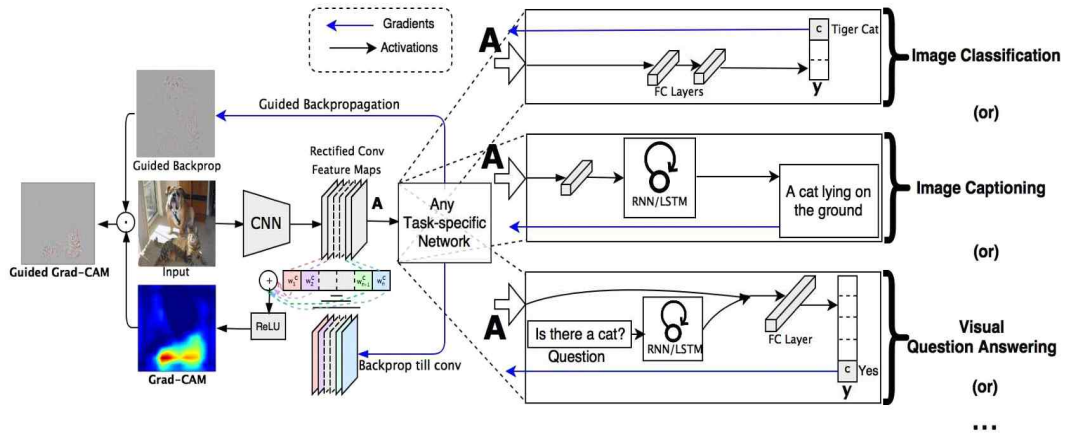


그림 4. Grad-CAM 개요(Selvaraju et al., 2017). 입력 이미지를 CNN 계층에 순전파하여 최종 클래스 점수(logit)를 계산한 후, 역전파를 통해 최종 출력층과 타깃 CNN 계층 사이의 기울기를 계산하고 이를 채널별 가중치로 부여하여 heatmap을 생성한다.

5.2 시각화 과정

EfficientNet-B1 모델은 “입력층 → 여러 개의 합성곱 계층(MBConv) → Fully Connected 계층 → 이진 분류기(classifier)”로 구성되어 있다. 이에 따라 Grad-CAM의 타깃 CNN 계층으로는 EfficientNet-B1의 마지막 MBConv 계층을 지정하였다. 학습이 완료된 EfficientNet-B1의 가중치를 사용하여 ‘yes’(오로라)와 ‘no’(비오로라) 클래스 각각의 출력값(logit)에 대해 기울기를 계산하고, 이를 활용하여 클래스별로 heatmap을 생성하였다.

III. 연구결과 및 해석

1. 오로라 분류 정확도 및 한계 분석

본 연구는 2022년 12월부터 2025년 2월까지의 331일치 AuroraMAX 전천 영상을 기반으로 총 214,890장의 이미지를 확보하였으며, Night & No_Moon 조건을 만족하는 총 98,126장 중 랜덤으로 추출된 4,563장의 전천 이미지에 대해 수작업 라벨링을 수행하였다. 오로라 이진 분류를 위해 클래스별로 1,024장씩 훈련 세트, 329장씩 검증 세트를 구성하였고, EfficientNet-B1 모델은 사전학습 가중치(ImageNet) 기반으로 초기 6 epoch 동안 classifier만 학습한 뒤, 이후 6 epoch 동안 전체 계층(backbone 포함)을 fine-tuning하였다.

1.1 모델 학습 결과

검증 데이터셋 기준 Loss는 학습 초기 0.33 수준에서 점차 감소하여, fine-tuning 이후에는 0.10 이하로 안정적으로 수렴하였다. 검증 Accuracy 또한 초기 86.47%에서 시작해 최고 95.59%까지 향상되었으며, 이는 오로라 영상의 특징을 효과적으로 학습하였음을 시사한다(그림 5). 훈련 지표 또한 유사한 수렴 경향을 보여, 과적합 현상은 관찰되지 않았다. 따라서 본 연구에서는 검증 Loss가 가장 낮고 검증 Accuracy가 가장 높은 Epoch 10의 모델 가중치를 저장하여 후속 분석에 활용하였다.

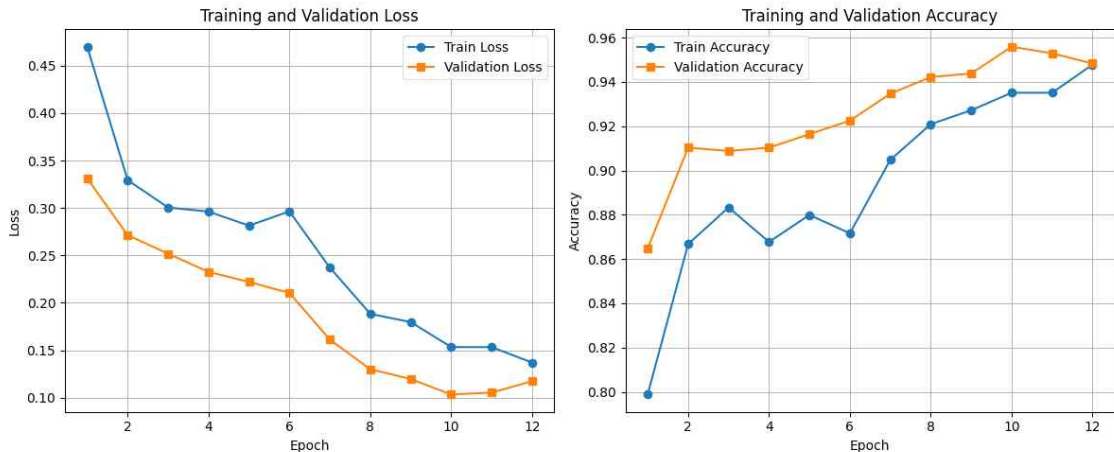


그림 5. 학습 및 검증 과정의 Loss 및 Accuracy 변화. EfficientNet-B1 모델은 총 12 epoch 동안 학습되었으며, Epoch 6 이후에는 backbone까지 fine-tuning을 수행하였다. 그 결과, Loss는 안정적으로 감소하였고 검증 Accuracy는 86.47%에서 시작해 최대 95.59%까지 향상되었다.

표 6. 시간대 및 달빛 조건에 따른 클래스 분포 결과
(총 214,890장)

Moon Phase		Night	Astro	Nautical
No_moon	yes	28162	7122	468
	no	69964	17027	1589
	ratio	40.3	41.8	29.5
Moon_Quarter	yes	12418	2719	215
	no	30943	7904	388
	ratio	40.1	34.4	55.4
Moon_Full	yes	8075	1720	114
	no	21441	4287	334
	ratio	37.7	40.1	34.1

본 모델을 이용하여 전체 테스트 이미지(총 214,890장)에 대해 “오로라(yes)”와 “비오로라(no)”의 이진 분류를 수행한 결과, 시간대(Night, Astro, Nautical) 및 월광 조건(No_moon, Moon_Quarter, Moon_Full)에 따른 분포는 위와 같다(표 6). 전체 평균 오로라 발생 비율은 39.3%로 확인되었다. Moon_Quarter&Nautical 조건은 오로라 발생 비율이 55.4%로 가장 높는데, 이는 모델이 FP(비오로라를 오로라로 분류) 혼란을 많이 겪음을 시사한다. 반면 No_moon&Nautical 조건은 오로라 발생 비율이 29.5%로 가장 낮는데, 이는 모델이 FN(오로라를 비오로라로 분류) 혼란을 많이 겪음을 시사한다.

1.2 softmax 확률 분석

EfficientNet-B1 모델이 입력 이미지에 대해 “오로라(yes)” 클래스를 얼마나 확신하는지를 softmax 확률로 분석하였다. 달 위상 및 시간대에 따른 평균과 표준편차는 다음과 같다(그림 6). softmax 확률의 평균은 전반적으로 배경 하늘이 밝아질수록 낮아지는 경향을 보였다. 반면, softmax 확률의 표준편차는 No_moon&Nautical, Moon_Quarter&Astro, Moon_Full&Night 조건, 즉 대각선상에 위치한 조합에서 두드러지게 높게 나타났다. 이는 태양 고도가 낮을수록 달빛의 상대적인 영향이 커지며, 모델의 불확실성 또한 증가함을 시사한다.

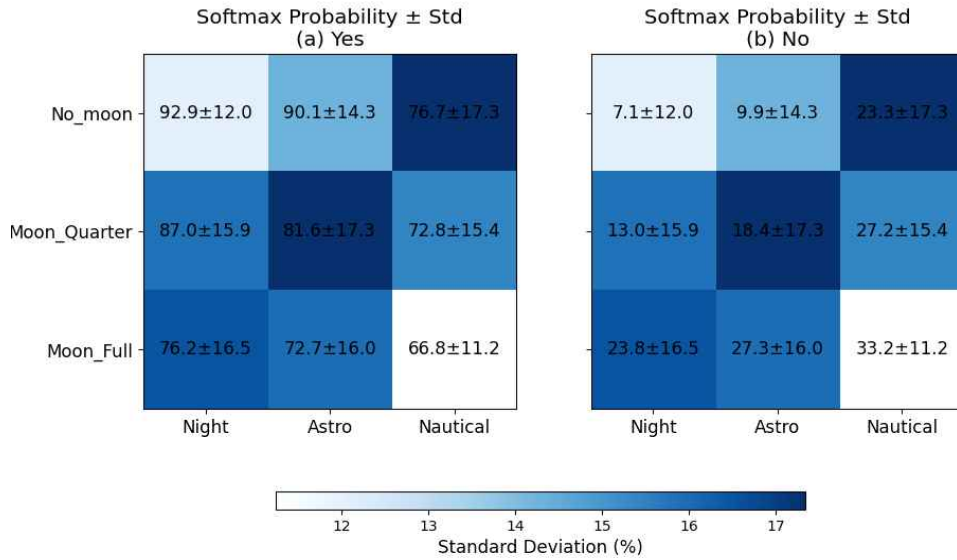


그림 6. 오로라(yes) 클래스에 대한 평균 softmax 확률과 표준편차. 각 셀의 값은 “평균 \pm 표준편차”를 나타내며, 컬러맵은 표준편차 크기에 따라 시각화되었다.

오로라(yes) 클래스에 대한 softmax 확률 분포를 히스토그램으로 나타내면 다음과 같다(그림 7). 어두운 Night 조건에서는 0%와 100% 근처에 뚜렷한 피크가 관찰되어, 모델이 양극단(완전 비오로라 혹은 완전 오로라) 예측에 높은 신뢰도를 부여함을 보여준다. 반면 Nautical twilight 조건에서는 확률 값이 비교적 고르게 분포하여 예측 확신도가 낮음을 시사한다. 특히 Moon Full 조건에서는 Night, Astro, Nautical 모든 시간대에서 분포가 중간 영역으로 넓게 퍼지고 피크가 완만해져, 모델의 불확실성이 전반적으로 증가했음을 확인할 수 있다.




그림 7. 오로라(yes) 클래스에 대한 softmax 확률 분포 히스토그램.


2. Grad-CAM 시각화 해석

yes 클래스 기준으로 계산된 Grad-CAM을 활용하여, 본 연구에서 학습한 EfficientNet-B1 모델이 오로라가 존재한다고 판단한 근거 영역을 시각적으로 분석하였다. 분석 대상은 Night 또는 No_Moon 조건에 해당하는 총 7개 범주로 구성되며, 이들은 모두 이

미지 중 대표 사례를 선별하여 진행하였다.


2.1 배경하늘 밝기

동일한 관측일 내에서 Night, Astro, Nautical 세 구간의 Grad-CAM 분포는 형상상 큰 차이를 보이지 않았다. 전체적으로 동일한 영역에 대해 집중도를 유지하였으며, Nautical 구간에서는 주변 배경 잡음이 약간 더 퍼져 보이지만 핵심 아치 패턴은 여전히 선명하게 포착되었다. 즉, 모델은 배경하늘의 전체 조도 변화보다는 대비가 강한 영역을 일관되게 신뢰하고 있음을 알 수 있다.



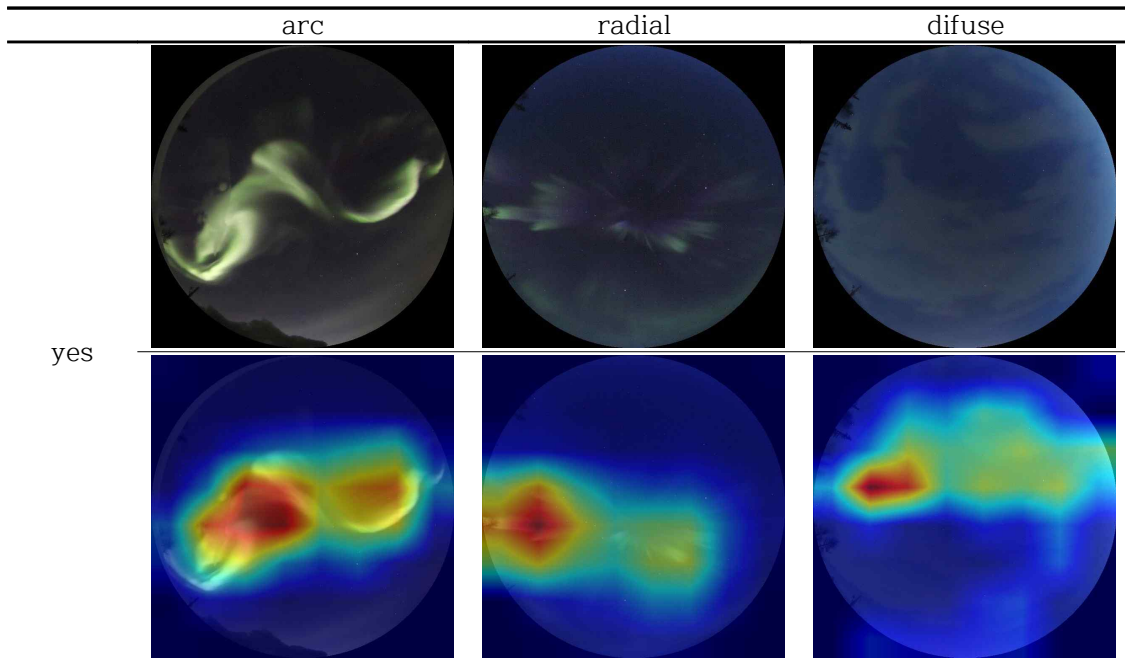
2.2 오로라 색깔

Red, Purple, Pink 세 가지 색상 사례 모두에서 채도가 높은 픽셀 군집에 높은 가중치가 부여되는 경향이 관찰되었다. 특히 Red 영역에서는 내부의 적색 띠가 가장 선명히 강조되었고, Purple의 경우에는 색상이 어두운 만큼 대비가 높은 외곽부가 넓게 활성화되었다. Pink 예시에서는 밝은 경계부가 주로 포착되어, 모델이 색상 그 자체보다는 “High-Saturation + High-Contrast” 특징을 기준으로 오로라를 감지함을 시사한다.




2.3 오로라 형태

Arc 형태에서는 굴곡을 따라 길게 이어진 밝기 경계가 열띤(red-hot) 히트맵으로 드러났고, Radial 형태에서는 중앙 지평선 근방에서 방사형으로 퍼져 나오는 구조적 패턴이 집중적으로 강조되었다. Diffuse 형태는 경계가 뚜렷하지 않아 전체적으로 넓게 분포된 약한 활성화 맵을 보였으나, 가장 밝은 패치 부근에서는 여전히 국소적인 피크가 형성되었다. 이를 통해 모델이 “급격한 밝기 변화”와 “구조적 연속성”을 복합적으로 활용하고 있음을 확인할 수 있다.



2.4 날씨

맑은 하늘(Clear)에서는 전반적으로 활성화가 사라져 모델이 정확히 비오로라를 식별함을, 구름(Cloud)과 눈(Snow) 이미지에서는 구름 및 지표면 반사부에 국소적 노이즈가 있으나 일정 기준 이하로 억제되어 오탐률이 낮음을 확인하였다. 이로써 EfficientNet-B1 분류기는 외란 요소에 대해서도 안정적인 판단 경계를 유지함을 알 수 있다.



VI. 결론 및 논의

1. 연구 요약 및 성과

본 연구는 2022-2025년(331일) AuroraMAX 전천 영상을 대상으로, EfficientNet-B1 전이학습 모델을 구축하여 오로라 유무를 자동 분류하고, softmax 확률과 Grad-CAM을 활용하여 분류 근거를 정량적으로 해석하였다. 연구 방법에서는 (1) 태양·달 고도 필터링으로 Night & No_Moon 조건을 선별해 잡음을 최소화하고, (2) 날짜별 무작위 샘플링과 수작업 라벨링을 통해 4,563장의 학습용 이미지를 구축한 뒤, (3) 클래스 균형을 맞춰 1,024장씩 훈련·검증 세트를 구성하였다. 전이학습은 ImageNet 사전학습 가중치를 적용해 12 epoch 동안 두 단계(classifier → fine-tuning)로 진행되었고, 최종 검증 정확도 95.6 %를 달성하였다.

연구 결과, 전체 214,890장의 테스트 이미지에 대해 평균 오로라 발생 비율은 39.3%로 나타났다. Moon_Quarter & Nautical 조건에서 FP가 많고 No_Moon & Nautical 조건에서 FN이 많음을 확인하였다. softmax 확률 분석은 달빛·황혼 밝기에 따라 모델 확신도가 체계적으로 변함을 보여 주었고, Grad-CAM 시각화는 모델이 채도가 높고 밝기 경계가 뚜렷한 영역을 주로 참조함을 시각적으로 검증하였다. 이는 기존 연구가 분류 정확도 향상에 머물렀던 한계를 넘어, 신뢰도 기반 오로라 강도 지표를 제안하고 물리적 해석 가능성을 확장했다는 점에서 의의가 있다.

2. 한계점 및 향후 연구 방향

이진 분류에 머물러 상세 형태(arc/patch/diffuse 등)나 강도 레벨을 구분하지 못했다. 또한 수동 라벨링 데이터가 적어 제대로 된 통계적 유의성(혼동행렬, F1 score)을 검증하지 못했다. 향후 Grad-CAM의 heatmap 면적·픽셀값을 이용한 정량 지표를 제안한다면 분류 시각을 기반으로 태양풍-지자기 지연 상관분석이 가능할 것이다. 이를 통해 향후 우주기상 예보 및 전리층 변화 예측 모델 개발에 실질적 기여를 할 수 있을 것으로 기대된다.

참 고 문 헌

- 안병호, & 지건화. (2014). 극지과학자가 들려주는 오로라 이야기. (그림으로 보는 극지 과학, Vol. 3). 지식노마드.
- Chollet, F. (2017). Xception: Deep learning with depthwise separable convolutions. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 1251-1258).
- Clausen, L. B., & Nickisch, H. (2018). Automatic classification of auroral images from the Oslo Auroral THEMIS (OATH) data set using machine learning. *Journal of Geophysical Research: Space Physics*, 123(7), 5640-5647.
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 770-778).
- Huang, G., Liu, Z., Van Der Maaten, L., & Weinberger, K. Q. (2017). Densely connected convolutional networks. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 4700-4708).
- Jee, G., Ham, Y. B., Choi, Y., Kim, E., Lee, C., Kwon, H., ... & Kim, J. H. (2021). Observations of the aurora by visible all-sky camera at Jang Bogo Station, Antarctica. *Journal of Astronomy and Space Sciences*, 38(4), 203-215.
- Johnson, J. W., Öztürk, D. S., Hampton, D., Connor, H. K., Blandin, M., & Keesee, A. (2024). Automatic detection and classification of aurora in Themis all-sky images. *Journal of Geophysical Research: Machine Learning and Computation*, 1(4), e2024JH000292.
- Karlsson, T., Andersson, L., Gillies, D. M., Lynch, K., Marghitu, O., Partamies, N., ... & Wu, J. (2020). Quiet, discrete auroral arcs—Observations. *Space Science Reviews*, 216, 1-50.
- Kingma, D. P., & Ba, J. (2014). Adam: A method for stochastic optimization. arXiv preprint arXiv:1412.6980.
- Kvammen, A., Wickstrøm, K., McKay, D., & Partamies, N. (2020). Auroral image classification with deep neural networks. *Journal of Geophysical Research: Space Physics*, 125(10), e2020JA027808.
- Partamies, N., Whiter, D., Syrjäso, M., & Kauristie, K. (2014). Solar cycle and diurnal dependence of auroral structures. *Journal of Geophysical Research: Space Physics*, 119(10), 8448-8461.

- Russakovsky, O., Deng, J., Su, H., Krause, J., Satheesh, S., Ma, S., ... & Fei-Fei, L. (2015). Imagenet large scale visual recognition challenge. *International journal of computer vision*, 115, 211-252.
- Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-cam: Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE international conference on computer vision* (pp. 618-626).
- Szegedy, C., Vanhoucke, V., Ioffe, S., Shlens, J., & Wojna, Z. (2016). Rethinking the inception architecture for computer vision. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 2818-2826).
- Tan, M., & Le, Q. (2019, May). Efficientnet: Rethinking model scaling for convolutional neural networks. In *International conference on machine learning* (pp. 6105-6114). PMLR.
- Yamauchi, M., & Brändström, U. (2023). Auroral alert version 1.0: two-step automatic detection of sudden aurora intensification from all-sky JPEG images. *Geoscientific Instrumentation, Methods and Data Systems*, 12(1), 71-90.
- Yang, Q., Liu, C., & Liang, J. (2021). Unsupervised automatic classification of all-sky auroral images using deep clustering technology. *Earth Science Informatics*, 14(3), 1327-1337.
- Yang, X., Wang, N., Song, B., & Gao, X. (2019). Aurora image search with saliency deep features. *IEEE Access*, 7, 65996-66006.

<부록 1> 논문발표회 발표자료

EfficientNet-B1 기반 오로라 이미지의 분류 및 시각화 분석

2148052 여정인

2025. 06. 20.

목차

1. 연구 배경	1	4. 딥러닝 접근 방법	4
- 오로라 직접 관측 경험		- 다양한 딥러닝 모델 시도	
- 극지연구소 인턴십		- EfficientNet-B1 선정 이유	
- 우주-대기-딥러닝 접점 탐구		- 딥러닝 전처리 과정	
2. 연구 동기 및 목표	2	5. 결과 및 분석	5
- 오로라 특성의 정량화		- 분류 정확도 분석	
- 태양풍 변수와의 연결		- GradCAM을 통한 시각화	
- 최소한의 지도학습		- 시간대별 성능 평가	
3. 데이터 선정	3	6. 결론 및 향후 계획	6
- AuroraMAX 데이터셋		- 연구의 주요 발견	
- 이미지 전처리 과정		- 한계점 및 개선 방향	
- 데이터 균형 확보 전략		- 향후 연구 계획 제시	

연구 배경



오로라 직접 관측 경험

- 캐나다 옐로나이프에서 2회 관측
- 실제 오로라 현상의 복잡성 인식 (규칙을 찾고 싶어짐)



극지연구소 인턴십

- 1주일 간의 딥러닝 전처리 실무 경험...
- 오로라 데이터의 복잡한 특성 이해 (해결하고 싶어짐)




우주-대기-딥러닝 접점

- 우주 기상과 지구 대기 현상 연계
- 딥러닝의 이미지 분석 능력 활용

연구 동기 및 목표

오로라 현상은 태양-지구 상호작용의 가시적 증거로, 우주 기상 연구에 중요한 역할을 한다. 본 연구는 딥러닝을 활용하여 오로라 이미지를 자동으로 분석하고, 이를 통해 태양풍 변수와의 관계를 규명하고자 했었...다.



1

최종 목표


- 오로라의 형태, 밝기, 곡률 정량화
- 태양풍 변수(Bz, Kp, Vsw 등)와 연결
- 우주 기상 예측 모델 개선에 기여
- 자동화된 오로라 분석 시스템 구축

2

현재 단계

- 오로라 존재 여부 이진 분류 (Yes/No)
- EfficientNet-B1 모델 적용 및 최적화
- GradCAM을 통한 모델 해석
- 오로라 분할 방법 찾는 중

데이터 선정 이유




AuroraMAX 프로젝트

- 캐나다 우주국 제공 공식 데이터
- 고품질 천천 카메라 영상 제공
- 장기간 연속 관측 데이터 확보
- 신뢰성 있는 연구 기반 마련



데이터 접근 유연성


- 대중과학 목적으로 홈페이지 제공
- 원하는 인터벌로 프레임 추출 가능
- 광해나 지형지물 적은 편



데이터 균형 확보

- 옐로나이프는 오로라 오벌 내 위치
- Yes/No 샘플 균형 확보 용이
- 모델 학습의 편향 방지

오로라 딥러닝의 어려움 (1)




일반 이미지


- 모양이 일정함
- 윤곽이 뚜렷함
- 불투명함
- ImageNET 학습 데이터 풍부
- 특징 추출이 용이함
- 분류 정확도가 높음

오로라 이미지

- 모양이 불규칙적
- 경계가 흐릿하고 투명함
- 배경이 매우 다양 (구름, 달, 눈)
- ImageNET 정답셋 부족
- 특징 추출이 어려움
- 분류 정확도 항상에 한계



오로라 딥러닝의 어려움 (2)



비지도 RGB 임계값 분할


- 알고리즘 단순화, 사전 학습 불필요
- 투명하여 배경하늘 영향 큼

비지도 VGG 특징 추출 및 군집화

- 수동 라벨링 불필요
- 블랙박스라 클러스터 의미 해석 주관

R-CNN 특징 추출 및 관심 영역 추출

- 100만장 수동 라벨링 필요
- 시각적 해석은 일지함



1



RGB/HSV 마스크

- RGB 및 HSV, YgCrCb 색공간 실험
조건: (g==v) & (s>=25) & (v-yg>1)
필크: ((h<=10)||h>=120)) & (cr>=cb) & (s>50) & (r>30)||((b==v) & (cr>130))
- 구름, 달 등 배경하늘에 따른 색감 차이 심함
- 2024년 이후 카메라 변경 문제

2

β -TCVAE

- 오로라 관련 잠재 특징 벡터 추출 시도
- 오로라 위치, 색감, 형태, 밝기 불규칙성 문제
- 블랙박스: UMAP, T-SNE, DBSCAN 모두 사용해봤으나 뚜렷한 군집을 찾지 못함



3


SimCLR + DBSCAN

- 대조 학습 기반 특징 추출
- 데이터 증강 기법 활용
- 클러스터링으로 그룹화 시도
- 전처리 없이 학습 불가 (loss 감소 X)

비지도 학습의 한계


- 오로라의 높은 변동성
- 배경과 오로라 구분 어려움
- 시간적 연속성 반영 부족
- 물리적 특성 고려 필요성 확인

전처리 과정 요약




영상 프레임 추출

- 331일치 영상 사용
- 1분 간격으로 추출
- 시간은 텍스트 추출




원형 마스크

- 원형 crop 적용
- 불필요한 지평선 제거



데이터 필터링

- 태양 고도 > -18°
- 보름달 고도 > 5°
- Quarter 달 고도 > 10°



수동 라벨링

- 날짜별 20장씩 총 4563장 처리
- Train: 1024장 * 2
- Validation: 326장 * 2

EfficientNet-B1 선택 이유

Tan, M., & Le, Q. (2019, 2020). EfficientNet: Rethinking model scaling for convolutional neural networks. In International conference on machine learning (pp. 3105-3134). PMLR.






Figure 1. Model Size vs. ImageNet Accuracy. All numbers are for single-crop, single-model. Our EfficientNets significantly outperform other ConvNets. In particular, EfficientNet-B7 achieves new state-of-the-art 84.4% top-1 accuracy but being 8.4x smaller and 6.1x faster than GPipe. EfficientNet-B1 is 7.6x smaller and 5.7x faster than ResNet-152. Details are in Table 2 and 4.



Compound Scaling

- 깊이, 폭, 해상도를 동시에 균형 있게 확장
- 적은 파라미터로 더 높은 정확도와 더 적은 계산량 달성
- RTX 2070 GPU로 2시간이면 처리 가능




I

전체 분류 정확도

- 다양한 오로라 형태와 밝기에 대해 높은 정확도의 이진 분류 성능 확보
- 구름 유무 및 형태와 관계없이 안정적인 식별 가능
- 특히 Night에서 오로라 유무를 효과적으로 구분함





2

오류 분석

- 밝은 부분이 없을 경우 No→Yes 오류 발생
 - Astro twilight 시점에서 오류율 증가
- 얇은 구름이 오로라처럼 보이는 경우 혼동 발생
- 배경과 오로라 사이 급격한 밝기 변화 경계에 주로 반응

오류 분석

- 시간 정보 활용 고려 중 (10분 전 오로라 유무 반영)
- 물리적 특성(곡선, RGB 등) 반영 고려 중
- Segmentation 활용 방안 검토 중

결론 요약

딥러닝 분류의 가능성

- 약 1천장만 지도하여 일정 수준 성과 달성
- EfficientNet-B1 모델의 효과적인 이진 분류
- 오로라 유무 이진 분류에서 높은 정확도 (0.96)
- 딥러닝의 오로라 연구 적용 가능성 확인

현재 한계점

- 복잡한 오로라 형태 완전 이해 부족
- 물리적 특성 반영 미흡

향후 연구 방향

- 물리 기반 특징 추출 방법 개발
- 세분화된 오로라 형태 분류 체계 구축
- 시공간적 변화 고려한 모델 설계
- 다중 스펙트럼 데이터 통합 분석

향후 계획

오로라 현상과 태양-지구 상호작용에 대한 이해를 높이고, 우주 기상 예측 능력을 향상시키는 것이 궁극적인 목표

1

오로라 지수 정량화

- 밝기, 면적, 곡률 기반 지수 개발
- 딥러닝 모델을 통한 자동 측정
- 시간에 따른 오로라 변화 추적
- 물리적 의미를 갖는 특징 추출

2

태양풍 상관관계 분석

- Bz, Kp, IMF 등 태양풍 변수 활용
- 시간지연 효과 고려한 상관관계 분석
 - 머신러닝 기반 예측 모델 개발
- 우주 기상 예보 정확도 향상 목표

참고문헌

- Tan & Le (2019). EfficientNet: Rethinking Model Scaling for CNNs. ICML.
- Chen et al. (2020). A Simple Framework for Contrastive Learning of Visual Representations. ICML.
- Jackel et al. (2021). Auroral Image Classification with Machine Learning. Space Weather.
- Zhang et al. (2020). Deep Learning for Night Sky Imaging. JGR Space Physics.
 - NOAA SWPC CME/Flare Data Archives
 - NASA OMNIWeb Database (Solar Wind Parameters)
 - AuroraMAX Live Canadian Space Agency
 - EfficientNet Wikipedia page